


Fonctionnement interne — agents-risques (projet E21)

Document **technique** : comment l'outil fonctionne de l'intérieur — architecture, flux de données, contrats JSON, mécanismes de sécurité, et correspondance avec les garde-fous du sujet et les recommandations OWASP LLM. Pour savoir quoi faire, voir `GUIDE_UTILISATION.md`.

Table des matières

- 1. Vue d'ensemble
- 2. Correspondance avec la démarche du cours
- 3. Architecture des composants
- 4. Contrat d'échange : l'enveloppe JSON
- 5. Séquence détaillée d'une analyse
- 6. Garde-fous de sécurité (G1→G10)
- 7. La matrice déterministe (G7)
- 8. Reprises et arrêt bavard (G8)
- 9. Recherche de connaissances (RAG) et base de connaissances (G10)
- 10. Le snapshot CVE
- 11. Comparaison avec la référence manuelle (`--comparer`)
- 12. Journalisation (G5)
- 13. Simulateur déterministe vs fournisseur réel
- 14. Modèle de données
- 15. Validation par agent : tableau de référence
- 16. Limites et points d'attention
- 17. Glossaire

1. Vue d'ensemble



[illegible]

2. Correspondance avec la démarche du cours

Étape	Composant	Cours
1. Décrire le système (DFD, frontières)	donnée statique (cases/* .md)	ch. 05-06
2. Inventorier les actifs	AG1 Inventaire	ch. 05
3. Choisir le modèle de menaces	AG2 Modèle (STRIDE + LINDDUN)	ch. 06, 10
4. Identifier les menaces (actifs × frontières)	AG3 Menaces	ch. 06, 10
5. Évaluer (probabilité × impact)	AG4 Évaluation (matrice)	ch. 05, p. 8 du sujet
6. Traiter (réduire/transférer/éviter/accepter)	AG5 Traitement	ch. 05
7. Valider humainement et publier	Orchestrateur + CLI	condition du sujet

3.1 `src/core/` — le socle (aucune IA)

Fichier	Rôle
config.py	constantes : échelles, matrice , traitements autorisés/interdits, tentatives max, seuils
models.py	dataclasses Actif, Menace, Evaluation, Risque (avec valide_par: str \ None)
schemas.py	les schémas JSON des échanges (enveloppe + sortie par agent)
validation.py	validations : schéma + règles métier (sources, valide_par , traitements, échelles, matrice, unicité)
sanitizer.py	filtrage anti-injection de prompt : détection, neutralisation, balisage « donnée »

Fichier	Rôle
<code>workspace.py</code>	mémoire partagée de la session (produits + statuts + registre) et persistance <code>workspace.json</code>
<code>journal.py</code>	journalisation horodatée append-only (<code>journal.jsonl</code>)

3.2 `src/tools/` — les outils (lecture seule, invoqués par l'orchestrateur)

Les agents **n'appellent aucun outil eux-mêmes** : l'orchestrateur délègue selon l'agent (`_OUTILS_PAR_AGENT` , cf. § 5) dans une `SandboxUtils` (liste blanche, `PermissionError` sinon).

Outil	Fonction	Gas
<code>lire_fichier</code>	lit un descriptif de système uniquement dans <code>cases/</code> (taille max, pas de <code>...</code> , pas d'écriture)	G2
<code>chercher_connaissance</code>	recherche RAG dans <code>knowledge/*.md</code> et renvoie extraits + références	G4, G10
<code>calculer_niveau</code>	applique la matrice $P \times I \rightarrow$ <code>niveau</code> (déterministe)	G7
<code>rechercher_cve</code>	interroge le snapshot local CVE/CVSS	G4

3.3 `src/llm/` — la couche modèle (remplaçable, G9)

Fichier	Rôle
<code>interface.py</code>	contrat FournisseurLLM (Protocol) + <code>extraire_json</code>
<code>dummy.py</code>	simulateur déterministe : reproduit la référence pour tester la chaîne — <code>nom_produit = "dummy-deterministic (test de chaîne – n'est PAS une analyse)"</code> ; paramètre <code>fidele=True/False</code> (False = registre valide mais divergent, cf. § 11)
<code>openai_compat.py</code>	fournisseur réel : POST <code>{base_url}/chat/completions</code> , <code>temperature=0.2</code> par défaut, <code>timeout</code> via <code>OPENAI_TIMEOUT</code> . Transport : curl système (TLS vérifié, clé hors argv via config <code>0600</code> éphémère), repli <code>urllib</code>

3.4 `src/agents/` — l'orchestration et les consignes

Fichier	Rôle
<code>base.py</code>	classe <code>Agent</code> : assemblage du prompt, réinjection des erreurs en reprise (<code>=== ERREURS DE LA TENTATIVE PRÉCÉDENTE ===</code>), mémorisation du dernier prompt (<code>_dernier_prompt</code>), point d'appel unique
<code>prompts.py</code>	les 5 consignes (AG1→AG5), le bloc système commun, listes d'outils et requêtes RAG

Fichier	Rôle
agents.py	les 5 classes concrètes + ordre d'exécution
orchestrator.py	pipeline (AG1→AG5), validation, reprises , normalisation déterministe, human loop, délégation des outils selon l'agent (<code>_OUTILS_PAR_AGENT</code>), <code>octets_entree</code> réels journalisés

3.5 `src/cli/` — le point d'entrée

Fichier	Rôle
main.py	argparse : sous-commandes <code>run</code> et <code>test-injection</code> , option <code>--comparer</code> (jalon 4) , session horodatée, écriture des 3 livrables

4. Contrat d'échange : l'enveloppe JSON

Toutes les sorties d'agents obéissent à **la même enveloppe** (`core/schemas.py`) :

```
{
  "agent": "AG3",
  "resume": "...",
  "sortie": { "..."},
  "sources": ["STRIDE", "01_Cadrage (frontières)",
  "incertitudes": []
}
```

- `sources` : **obligatoire, non vide** (G4 — parade anti-hallucination).
- `incertitudes` : facultatif — l'agent y signale ce qu'il ne sait pas.
- `valide_par` : **n'apparaît pas** dans cet échange, et quand il apparaît dans un risque il doit être `null` (G6). Le schéma AG5 impose même `"type": "null"`.

Les schémas de `sortie` par agent (cf. `SCHEMAS_SORTIE`) :

Agent	<code>sortie</code> contient	Contraintes notables
AG1	<code>actifs[]</code>	<code>id = A-\d{2}</code> , type parmi 6 valeurs, <code>criticite</code> ∈ {C,I,A}, <code>valeur</code> parmi 4
AG2	<code>modele_retenu</code> , <code>modeles_complementaires</code>	Échelles normalisées (aucun échec, aucune évaluation, aucun doublon)
AG3	<code>menaces[]</code>	<code>id_menace = M-\d{2}</code> , <code>frontiere = "1"..."6"</code> , <code>categorie = STRIDE-... ou LINDDUN-...</code>
AG4	<code>evaluations[]</code>	<code>id_menace = M-\d{2}</code> , P/I dans les échelles de configuration

Agent	contient	Contraintes notables
AG5	risques[]	id = R-\d{2}, menace_id requis, traitement ∈ 4 réponses, valide_par null

additionalProperties: true permet aux agents d'enrichir (ex. menace_id, contraintes), sans jamais supprimer les champs requis.

5. Séquence détaillée d'une analyse

Entrée (CLI commande_run) : 1. lire_fichier("cases/casB_mediconsult.md") — lecture seule, chemin restreint, ≤ 100 000 octets.

Phase 1 — assainissement (Orchestrateur.analyser) : 2. sanctionner_document(description) : a. **normalisation préalable** du texte (homoglyphes cyrilliques/grecs/fullwidth → latin, caractères zero-width et diacritiques combinants retirés, espaces écrasés, \n préservés) puis **détection par OCCURRENCE** des motifs d'injection (regex FR/EN + variantes paraphrasées, tolérant l'obfuscation inter-lettres \s*); b. neutralisation ([DONNEE-NON-EXECUTABLE]) — toute balise <<<...>>> déjà présente dans le document est neutralisée (motif delimitateur_injecte, ex. <<<FIN-DONNEES>>>, pour ne pas permettre la fermeture du bloc); c. balisage en bloc **donnée** : <<<DONNEES-{jeton}>>> ... <<<FIN-{jeton}>>> avec un **jeton aléatoire unique par session** (secrets.token_hex(5), cf. _generer_delimitateurs) — impossible à anticiper par un document piégé. 3. si détections → événement injection_detectee dans le journal (**une entrée par occurrence** : les 14 instructions de casB_injecte.md → 14 entrées). 4. le contexte_metier (si fourni) subit le même traitement (G1) avant injection.

Phase 2 — boucle agent par agent (ordre AG1→AG5) :

Pour chaque agent A : 5. _preparer_rag(A) : les requêtes RAG de REQUETES_RAG[A] sont exécutées sur la base de connaissances ; les extraits (dédoublonnés, ≤ 6) sont injectés dans le prompt. 6. si A == AG3 : _preparer_cve_ag3(description_systeme) complète le contexte — les mots-clés sont **extraits du document étudié** (extraire_technologies, cf. § 10) ; repli documenté si le document n'en contient aucun. 7. agent.definir_contexte(contexte) : l'agent reçoit les sorties normalisées des étapes précédentes (actifs, modèle, menaces, évaluations). 8. **Le prompt est assemblé** (base.Agent.construire_prompt) : marqueur + consigne + outils + connaissances(RAG) + DONNEES + format attendu + rappels de sécurité ; en cas de reprise, le bloc === ERREURS DE LA TENTATIVE PRÉCÉDENTE (à corriger impérativement) === est ajouté (la reprise n'est jamais un simple doublon). 9. agent.produire() → un appel LLM (llm.complete(système, utilisateur)) ; le prompt construit est mémorisé dans agent._dernier_prompt — sa longueur est journalisée comme **octets_entree réels** du journal. 10. le brut est parsé en JSON (json.loads), sinon echec_json → reprise (voir §8). 11. toutes_les_erreurs(...) : pile de validation (schéma, sources, valide_par, règles métier propres à l'agent). 12. si A == AG4 et pas d'erreur : _appliquer_niveaux_deterministes recalcule chaque niveau via la matrice — **le LLM ne décide jamais du niveau** (G7). 13. si aucune erreur → statut_ok, la sortie est mémorisée dans le workspace (set_etape) et **normalisée** pour l'étape suivante (_injecter_etape). 14. sinon → echec_schema, les erreurs sont réinjectées comme erreurs_reparation dans le prompt du prochain essai (retour de correction), jusqu'à 3 tentatives. 15. au-delà de 3 tentatives → **EtapeImpossibleError** : arrêt explicite (G8), aucun fichier de résultat n'est publié, le CLI sort en code 1.

Phase 3 — validation humaine (valider_humainement) : 16. registre_provisoire() : copie profonde des risques d'AG5 (le produit d'AG5 n'est **jamais muté**), avec valide_par = null. 17. pour chaque risque : question interactive a/d/c ; c (_corriger_risque) permet de modifier **actif, probabilité, impact, traitement, sources** et le texte de la menace — une correction de P/I **recalcule le niveau par la matrice**

(jamais corrigé à la main, G7). 18. chaque décision → événement `validation_humaine` (accepte / diffère / corrige) ; chaque champ modifié → événement `correction_humaine` (champs + `valide_par`). Un risque **différé** garde `valide_par = null`.

Phase 4 — persistance : 19. `workspace.set_final(registre)` puis `workspace.sauvegarder()` → `workspace.json`. 20. `registre_final.json` est écrit ; événement `session_fin` horodaté.

6. Garde-fous de sécurité (G1→G10)

Correspondance exacte avec le référentiel du projet (p. 20 du sujet) et OWASP LLM :

#	Garde-fou	Mécanisme réel	Code	OWASP
G1	Filtrage des entrées (injection)	normalisation puis détection par occurrence (11 motifs FR/EN + paraphrases, obfuscation tolérée) + neutralisation + séparation consigne/donnée (délimiteurs aléatoires uniques par session) + <code>contexte_metier</code> assaini	<code>core/sanitizer.py</code> , 2-4)	LLM01 / <code>orchestrator.py</code> (étapes 1-4)
G2	Outils lecture seule	registre d'outils + <code>SandboxOutils</code> ; liste blanche par agent déléguée par l'orchestrateur (<code>_OUTILS_PAR_AGENT</code> , les agents n'appellent rien eux-mêmes, <code>PermissionError</code> sinon) ; <code>lire_fichier</code> restreint à <code>cases/</code>	<code>tools/registry.py</code> , 1-3)	LLM06 / <code>file_reader.py</code> , agents 1-3
G3	Anonymisation	cas d'étude fictif ; avertissement explicite pour le mode réel ; zéro donnée réelle dans le pipeline	<code>README.md</code> , prompts	LLM02

#	Garde-fou	Mécanisme réel	Code	OWASP
G4	Sources citées	sources requis non vide par le schéma (enveloppe) et par risque AG5, avec contrôle de format : « aucune/néant/none/n/a/inconnu » rejetés, 3 à 120 caractères ; RAG renvoie reference à recopier	core/validation.py, tools/knowledge.py	LLM07 (anti-poisoning)
G5	Journalisation	journal JSON-lines horodaté de chaque appel, chaque outil, chaque décision	core/journal.py	—
G6	Validation humaine	valide_par écrit uniquement par schéma AG5 ; impose "type": "null" ; la chaîne "null" est rejetée	core/validation.py, core/schemas.py, agents/orchestrator.py	—
G7	Niveau déterministe	matrice P×I appliquée par l'orchestrateur (AG4) et re-vérifiée sur chaque risque final (AG5) ; aucune « auto-autorisation » d'échelle inventée	tools/matrice.py, core/validation.py, agents/orchestrator.py	LLM08 (overreliance)
G8	Arrêt bavard	3 tentatives max par étape, puis exception et code 1 — jamais de remplissage	agents/orchestrator.py, cli/main.py	LLM08 (excessive agency)
G9	Modèle remplaçable	interface FournisseurLLM (Protocol) ; dummy ■ openai_compat sans toucher au reste	llm/interface.py	—
G10	Connaissances versionnées, lecture seule	knowledge/*.md en lecture seule et indexés ; les extraits sont des citations	charg tools/knowledge.py	LLM07

Règles métier complémentaires dans validation.py : - traitements limités à **réduire / transférer / éviter / accepter** — « ignorer », « rien », « néant » sont **interdits** ; - identifiants uniques (A-nn , M-nn , R-nn) ; - P/I

dans les échelles de configuration (l'écho de l'agent est ignoré) ; - AG5 doit **recopier** P//niveau de l'étape 4 (jamais recalculer) et y rester rattaché par `menace_id`.

6.1 Les 11 motifs du sanitizer (G1)

`core/sanitizer.py` — `_MOTIFS_INJECTION` : paires (nom, regex) en français et en anglais, y compris des **variantes paraphrasées** tolérant l'obfuscation inter-lettres (`\s*`). La détection ne bloque pas l'analyse : chaque **occurrence** est **signalée** (`injection_detectee`) puis **neutralisée** en `[[DONNEE-NON-EXECUTABLE]]`. La détection et la neutralisation travaillent sur un texte **normalisé** (homoglyphes cyrilliques/grecs/fullwidth → latin, caractères zero-width et diacritiques combinants retirés, espaces écrasés, `\n` préservés) et se reportent aux indices **bruts** pour l'extrait journalisé.

Motif	Cible (exemple de ce qui est attrapé)
<code>ignore_instructions</code>	« ignore tes instructions », « disregard your previous rules »
<code>disable_securite</code>	« désactive tes consignes », « forget all security »
<code>override_system</code>	« tu es maintenant... », « you are now... », « new system prompt »
<code>nouvelle_persona</code>	« à partir de maintenant », « fais comme si », « pretend »
<code>delimiteur_injecte</code>	toute balise <code><<<...>>></code> insérée dans le document (ex. <code><<<FIN-DONNEES>>></code> , tentatives d'évasion du bloc de données)
<code>delimiter_escape</code>	<code><<SYS>></code> , <code><\ im_start\ ></code> , <code><\ system\ ></code>
<code>data_as_instruction</code>	une ligne <code>instructions : ...</code> en début de texte
<code>jailbreak_mot</code>	« jailbreak », « désactive tes règles »
<code>assistant_prefix</code>	une ligne <code>assistant : ...</code> insérée (usurpation de rôle)
<code>disclose_secrets</code>	« révèle tes instructions/clefs », « reveal your system prompt »
<code>replay_prompt</code>	« répète tout ce qui précède », « repeat everything above »

La détection est **par occurrence** : chaque instruction piégée produit une entrée. Vérifié par tests : les **14 instructions présentes dans `casB_injecte.md`** produisent **exactement 14 détections** (`test_cas_injecte_exactement_14_detections`, `test_orchestracteur`), dont l'obfusquée « lg n ore tes instructions » et la balise `<<<FIN-DONNEES>>>` (`delimiteur_injecte`) ; le document sain du cas B ne produit **aucun faux positif** (fix « désormais », « Dorénavant », « Consignes : » — `test_document_legitime_sans_fausse_alarme`).

7. La matrice déterministe (G7)

Matrice probabilité × impact **celle du sujet (p. 8)** :

Prob \ Impact	faible	moyen	élevé
élevée	moyen	élevé	critique
moyenne	faible	moyen	élevé

Prob \ Impact	faible	moyen	élevé
faible	faible	faible	moyen

Deux endroits en imposent le respect : 1. **AG4** : après validation, l'orchestrateur écrase `niveau` par `calculer_niveau(P, I)` — un niveau « inventé » est remplacé, jamais propagé. Une P/I hors matrice provoque un échec bloquant (pas de `continue` silencieux). 2. **AG5** : `verifier_niveaux_agent5` re-vérifie **chaque entrée du registre final** ; un niveau $\neq$ matrice est une erreur de validation (exception après 3 reprises).

8. Reprises et arrêt bavard (G8)

Boucle de reprise (`_executer_avec_reprises`) :

```
pour tentative = 1..3 :
  1. appel LLM
    ■■ exception réseau/API → echec_llm → rejouer (même prompt)
    ■■ JSON invalide → echec_json → rejouer avec erreurs_reparation
    ■■ JSON valide → toutes_les_erreurs(...)
    ■■ 0 erreur → le niveau AG4 est recalé, retour sortie ■
    ■■ erreurs → echec_schema → rejouer avec erreurs_reparation
après 3 tentatives → EtapeImpossibleError (code 1, aucun livrable publié)
```

La **réparation** consiste à réinjecter les erreurs de la tentative précédente dans le prompt du tour suivant, sous le bloc `=== ERREURS DE LA TENTATIVE PRÉCÉDENTE (à corriger impérativement) ===` : l'agent sait *pourquoi* sa sortie a été refusée. Le dernier prompt construit est mémorisé sur `Agent._dernier_prompt` (c'est sa taille qui est journalisée en `octets_entree`). Les messages d'erreur sont **tronqués à 160 caractères** avant journalisation (pas de fuite de contenu LLM).

9. Recherche de connaissances (RAG) et base de connaissances (G10)

RAG minimaliste, sans dépendance vectorielle :

1. `knowledge/` contient 5 documents Markdown : `stride.md`, `linddun.md`, `iso27002.md`, `anssi.md`, `attck.md`.
2. À chaque démarrage, `BaseConnaissances` les charge et les **découpe en blocs** (par titre `#`).
3. `chercher_connaissance(requête)` : mots-clés (≥ 3 lettres, mots vides exclus) → score de cooccurrence par bloc → les **top extraits** sont renvoyés avec leur **référence** (`knowledge/stride.md` · `STRIDE – grille d'identification`).
4. L'orchestrateur pré-extraie **par agent** (requêtes fixes de `REQUETES_RAG`) et injecte ≤ 6 extraits dans le prompt.
5. L'agent est invité à **recopier ces références dans sources** — d'où la vérification G4.

C'est une forme de *grounding* : le modèle répond à partir d'un corpus contrôlé et citable, au lieu de puiser dans sa seule mémoire.

10. Le snapshot CVE

data/cve_snapshot.json : 5 CVE réelles avec score CVSS et référence NVD.

- `rechercher_cve(mots=..., version=...)` filtre par mots-clés ; **sans critère**, réponse vide.
- Utilisé pour **AG3** : `_preparer_cve_ag3(document)` **extraire les mots-clés technologiques du document étudié** via `extraire_technologies(document)` (`webRTC`, `tls`, `api`, `visio`, ... — l'extraction se fait sur la donnée, pas sur une liste codée en dur) ; si le document n'en contient aucun, un **repli documenté** est utilisé (`webRTC` `tls` `api`) et l'absence de mot-clé est assumée. (tests : `test_extraire_technologies_depuis_document`, `test_preparer_cve_repli_decentralise`).
- ■■ C'est un **instantané de démonstration**, figé : la fonction renvoie en toutes lettres qu'il ne faut pas en inventer d'autres et qu'il faut consulter le **NVD** en production. Cette limitation est volontaire et documentée (anti-hallucination).

11. Comparaison avec la référence manuelle (`--comparer`)

`src/core/comparaison.py` — `comparer_registres(genere, reference)` aligne deux registres par identifiant R-nn (ne mute aucun argument) et retourne un dict : `nb_reference`, `retrouves`, `inventes`, `oublies`, `ecarts_par_risque` (sur les champs `actif`, `probabilite`, `impact`, `niveau`, `traitement`), `nb_ecarts_niveau`, `taux_reconciliation` et `synthese` (prête à afficher).

- **Référence** : `data/reference_manuelle.json` (structure `{"risques":[...]}`, alimentée par `03_Analyse_Manuelle_Reference.md` — vérité terrain humaine).
- **CLI** : `python run.py run --case cases/casB_mediconsult.md --no-human --comparer` affiche la synthèse et les écarts détaillés ; `data/reference_manuelle.json` absent → le CLI le signale sans bloquer.
- ■■ **Honnêteté (tautologie assumée)** : en dry-run, `FournisseurSimule(fidele=True)` REPRODUIT la référence pour tester la chaîne — le score affiché ne prouve rien sur la qualité de l'analyse. Le CLI l'affiche explicitement : « mode dummy : comparaison tautologique par conception — relancer avec `--provider openai` pour une vraie comparaison agents ↔ humains ».
- **Preuve de non-tautologie** : `FournisseurSimule(fidele=False)` (tests) produit un registre **valide pour le pipeline** mais **divergent** — R-07 oublié, R-11 inventé, R-09 avec écart de niveau, R-08 avec traitement différent. `test_comparaison.py` vérifie que `comparer_registres` détecte précisément ces écarts (`oublies == ["R-07"]`, `inventes == ["R-11"]`, `nb_ecarts_niveau ≥ 1`).
- **Mode réel** : `--provider openai` lit `OPENAI_BASE_URL` (défaut `https://api.openai.com/v1`), `OPENAI_API_KEY` et `OPENAI_MODEL` (variables d'environnement uniquement) ; `temperature=0.2` par défaut (`src/llm/openai_compat.py`). Seule une exécution réelle permet une comparaison agents ↔ humains qui ait un sens.

12. Journalisation (G5)

`core/journal.py` — écriture **append-only** en JSON-lines, horodatage UTC ISO-8601.

Événements émis :

Événement	champs	émis par
<code>session_debut</code> / <code>session_fin</code>	<code>chemin</code> / <code>statut</code> , <code>nb_risques</code>	CLI, orchestrateur
<code>session_fin_motif</code>	<code>motif</code> (arrêt bavard)	CLI (erreur G8)

Événement	champs	émis par
appel_agent	agent, tentative, statut (ok / echec_schema / echec_json / echec_llm / outil), outils, octets_entree / octets_sortie réels, erreurs	orchestrateur, sandbox
injection_detectee	liste {motif, extrait} — une entrée par occurrence	orchestrateur (G1)
rag_echec	agent, erreur	orchestrateur
validation_humaine	risque, valide_par, décision (accepte / differe / corrige)	orchestrateur
correction_humaine	risque, valide_par, champs modifiés (menace, actif, probabilité, impact, traitement, sources)	orchestrateur (§ _corriger_risque)

13. Simulateur déterministe vs fournisseur réel

FournisseurSimule (dummy.py) - Sert les sorties figées qui correspondent à l'analyse manuelle de référence (14 actifs, STRIDE+LINDDUN, 10 menaces, 10 évaluations, 10 risques) — **pour tester la chaîne** : son nom_produit est explicite, dummy-deterministic (test de chaîne – n'est PAS une analyse). - Routage par marqueur dans le prompt (__AGENT_1_INVENTAIRE__ ...). - Paramètre **fidele=True/False** : False produit un registre **valide pour le pipeline mais divergent** (R-07 oublié, R-11 inventé, R-09 écart de niveau, R-08 autre traitement) — utilisé par test_comparaison.py pour prouver que la comparaison n'est pas tautologique (cf. § 11). - Un mode troubler=True (tests uniquement) produit des sorties **volontairement invalides** (valide_par rempli, sources vides, traitement « ignorer », niveau faux) pour prouver que les garde-fous bloquent. - Usage : démo sans clé, tests déterministes. En dry-run, un affichage « 10/10 vs référence » ne prouve que la cohérence du pipeline — jamais la qualité de l'analyse.

OpenAICompatProvider (openai_compat.py) - POST {base_url}/chat/completions avec messages=[system, user], temperature=0.2 (défaut), timeout=120. - Clé et modèle **uniquement** via variables d'environnement (OPENAI_BASE_URL , OPENAI_API_KEY , OPENAI_MODEL — aucun secret en dur). - extraire_json (interface.py) : si la réponse est bavarde, extrait le premier {...} au dernier } ; sinon ValueError → reprise. - ■■ Ne jamais envoyer de **données réelles** (G3). Seul ce fournisseur rend la comparaison --comparer signifiante.

Remplaçabilité (G9) : tout objet implémentant complete(système, utilisateur) → str (contract FournisseurLLM) peut être branché sans modifier le pipeline.

14. Modèle de données

Dataclasses (core/models.py) — miroir exact des schémas JSON :

- **Actif** : id, nom, type, description, criticite, valeur, propriétaire, contraintes
- **Menace** : id_menace, actif, frontiere, description, categorie, vulnerabilite, source_menace
- **Evaluation** : id_menace, probabilite, impact, niveau, justification
- **Risque** : id, actif, menace_id, menace, categorie, probabilite, impact, niveau, traitement, mesures, justification, sources, risque_residuel, propriétaire, valide_par

L'enveloppe (agent, resume, sortie, sources, incertitudes) est le seul format qu'un agent peut rendre ; le workspace stocke ces enveloppes validées et normalisées.

15. Validation par agent : tableau de référence

Récapitulatif des vérifications appliquées à chaque étape (toutes_les_erreurs) :

Étape	Schéma	Sources ≥ 1 (format valide)	valide_par = null	Unicité ids	Autre règle
AG1	■	■	–	id actifs	type, criticite, valeur c les énumérations (via schéma)
AG2	■	■	–	–	échelles normalisées sans doublons
AG3	■	■	–	id_menace	frontiere ∈ 1..6, categorie ∈ STRIDE/LINDDUN (via schéma)
AG4	■	■	–	id_menace	P/I dans les échelles de configuration ; niveau recalculé (pas d'écho)
AG5	■	■	■	id	menace_id requis + connu ; traitement autorisé (« ignorer » interdit) ; P/I/niveau = étape 4 ; niveau = matrice

16. Limites et points d'attention

- Sanitizer à base de motifs** : il détecte les injections connues (11 motifs FR/EN + paraphrases, § 6.1). Il ne prétend pas à l'exhaustivité — la **séparation consigne/donnée** (délimiteurs uniques par session) et la **validation stricte des sorties** sont les couches réellement décisives (défense en profondeur, à l'image du cours).
- CVE figées** (cve_snapshot.json) : ce sont des données de démo ; en production il faut interroger le NVD. La fonction refuse d'ailleurs d'en inventer.
- MAX_PROMPT_OCTETS** : constante définie dans config.py mais **pas encore exploitée** (le prompt est borné indirectement par MAX_DOCUMENT_OCTETS).
- RAG simple** : recherche par mots-clés, pas de plongements vectoriels — c'est un choix pédagogique (aucune dépendance, reproductibilité totale).

5. **Échelles normalisées** : AG2 choisit ses échelles « pour la vitrine » mais la validation utilise les échelles de `config.py` — volontaire : les 3 valeurs du sujet sont la référence commune.
6. **Dry-run vs réel** : le simulateur reproduit la référence manuelle pour tester la chaîne — il **n'est pas** une analyse, et la comparaison `--comparer` en dry-run est **tautologique** (le CLI le rappelle). Seul le mode réel (`--provider openai`) fait varier les réponses : c'est la seule comparaison qui ait un sens, complétée par la grille C1→C10 du jalon 4. La non-tautologie de l'outil de comparaison est prouvée par le mode `fidele=False` (écarts détectés, cf. § 11).

17. Glossaire

Terme	Définition
Agent	composant IA qui produit une étape de l'analyse (un prompt + outils + contrat de sortie)
Orchestrateur	coordonne les agents : contexte, validation, reprises, mémoire, journal
Enveloppe	contrat JSON commun de sortie (<code>agent</code> , <code>resume</code> , <code>sortie</code> , <code>sources</code> , <code>incertitudes</code>)
RAG	<i>Retrieval-Augmented Generation</i> : injection d'extraits d'une base de connaissance dans le prompt
Sanitizer	filtre d'entrée : détecte/neutralise les tentatives d'injection de prompt
Matrice P×I	outil déterministe « probabilité × impact → niveau » (le LLM n'en décide pas)
Arrêt bavard	en cas de rejet répété (3×), l'outil s'arrête en erreur au lieu d'inventer
<code>valide_par</code>	champ signé par l'humain uniquement ; <code>null</code> tant que rien n'est validé
Sémantique des traitements	réduire / transférer / éviter / accepter ; « ignorer » toujours interdit
Snapshot CVE	jeux de données CVE/CVSS local et figé, à rafraîchir via le NVD en production
Comparaison (<code>--comparer</code>)	alignement du registre généré vs <code>data/reference_manuelle.json</code> ; tautologique en dry-run, signifiante en mode réel
Référence manuelle	<code>data/reference_manuelle.json</code> , vérité terrain humaine issue de <code>03_Analyse_Manuelle_Reference.md</code>

Références croisées : `README.md` (vue raccourcie), `GUIDE_UTILISATION.md` (quoi faire), `../02_Architecture_MultiAgents.md` (conception), `../03_Analyse_Manuelle_Reference.md` (référence manuelle), `../04_Tests_Comparaison_Agents.md` (résultats de tests), `../07_Guide_Repetition_Soutenance.md` et `../08_Demo_Scriptee.md` (préparation soutenance), `../outils/md_to_pdf.py` (génération des PDF des livrables).